

FACULTAD DE CIENCIAS FÍSICO MATEMÁTICAS
MAESTRÍA EN CIENCIA DE DATOS

**”Modelo de predicción del torque
y temperatura en motores
síncronos de imanes permanentes
mediante redes neuronales no
lineales”**

Marco Antonio Obregón Flores

Profesor:

José Alberto Benavides Vazquez

18 de febrero de 2023

Abstract

Este artículo se enfoca en la predicción del torque y la temperatura del estator en motores síncronos de imanes permanentes mediante modelos de regresión. Se discute el modelo de regresión no lineal basado en redes neuronales, también conocido como red neuronal artificial (ANN), como uno de los modelos más efectivos y ampliamente utilizado. La ANN puede aprender relaciones no lineales entre entradas y salidas mediante el ajuste de los pesos de las conexiones entre las neuronas, lo que la hace adecuada para la predicción de datos complejos y no lineales como la temperatura y el torque en motores síncronos de imanes permanentes. Se presentan diferentes algoritmos de optimización, incluyendo el algoritmo de retropropagación y el algoritmo de Levenberg-Marquardt, y se discute la aplicación de técnicas de regularización como la regularización bayesiana para evitar el sobreajuste del modelo.

1 Introducción

La temperatura es una de las variables más críticas en la operación de los motores eléctricos, ya que puede afectar su rendimiento y vida útil. En particular, en los motores síncronos de imanes permanentes, las altas temperaturas en el devanado del estator, el diente del estator y el yugo del estator pueden afectar la eficiencia y la estabilidad del motor. Por lo tanto, es importante medir y controlar estas temperaturas durante la operación del motor.

En la actualidad, existen diversas técnicas para medir las temperaturas en diferentes partes del motor, como el uso de termopares y unidades de termografía. Además, se pueden utilizar modelos de regresión para predecir estas temperaturas a partir de otras variables medidas en el motor, como la corriente, el voltaje y la velocidad.

Existen varias variables que influyen en la temperatura del estator, como la temperatura del refrigerante (**coolant**), la temperatura del devanado del estator (**stator_winding**) medida con termopares, la temperatura del diente del estator (**stator_tooth**) medida con termopares, la velocidad del motor (**motor_speed**), la corriente del componente d en coordenadas dq (**i.d**), la corriente del componente q en coordenadas dq (**i.q**), la temperatura de imán permanente (**pm**) medida con termopares y transmitida de forma inalámbrica a través de una unidad de termografía, y la temperatura del yugo del estator (**stator_yoke**) medida con termopares.

En este artículo, nos enfocamos en la predicción del torque y la temperatura del estator en motores síncronos de imanes permanentes mediante modelos de regresión. En particular, se discute el modelo de regresión no lineal basado en redes neuronales, también conocido como red neuronal artificial (ANN), como uno de los modelos más efectivos y ampliamente utilizado. La ANN puede aprender relaciones no lineales entre entradas y salidas mediante el ajuste de

los pesos de las conexiones entre las neuronas, lo que la hace adecuada para la predicción de datos complejos y no lineales como la temperatura y el torque en motores síncronos de imanes permanentes.

2 Metodología Propuesta

En el desarrollo del modelo de predicción se consideraron los factores que afectan el torque del motor y la temperatura del estator, como la velocidad del motor, el voltaje y la corriente de los componentes d y q, y las temperaturas ambiental y del refrigerante. Por lo tanto, en este artículo se consideraron siete parámetros de entrada: la temperatura ambiente, la temperatura del refrigerante, el componente d del voltaje, el componente q del voltaje, la velocidad del motor, el componente d de la corriente y el componente q de la corriente. Los parámetros de salida considerados son el torque del motor y las temperaturas en la superficie del imán permanente, el yugo del estator, el diente del estator y el devanado del estator.

El procedimiento para obtener el proceso de predicción consiste en los siguientes pasos:

1. **Preprocesamiento de datos:** Se realiza una limpieza y preparación de los datos, eliminando valores faltantes o inconsistentes y normalizando los datos si es necesario.
2. **Selección de características:** Se seleccionan las características relevantes que se utilizarán en el modelo de predicción. En este caso, se considerarán las variables mencionadas en la introducción.
3. **División de datos:** Se divide el conjunto de datos en dos partes, una para entrenar el modelo y otra para probar su rendimiento.
4. **Entrenamiento del modelo:** Se selecciona el modelo de regresión no lineal basado en redes neuronales y se entrena con el conjunto de datos de entrenamiento. Se utilizan diferentes algoritmos de optimización, como el algoritmo de retropropagación o el algoritmo de Levenberg-Marquardt, y se aplican técnicas de regularización como la regularización bayesiana para evitar el sobreajuste del modelo.
5. **Evaluación del modelo:** Se evalúa el rendimiento del modelo utilizando el conjunto de datos de prueba. Se calculan métricas como el error cuadrático medio (MSE) y el coeficiente de determinación (R^2) para evaluar la precisión del modelo.

Error cuadrático medio (MSE): La fórmula matemática del MSE es:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Donde y_i es el valor real de la variable a predecir, \hat{y}_i es el valor predicho por el modelo y n es el número total de observaciones.

Coefficiente de determinación (R^2): La fórmula matemática del R^2 es:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Donde y_i es el valor real de la variable a predecir, \hat{y}_i es el valor predicho por el modelo, \bar{y} es la media de los valores reales y n es el número total de observaciones.

6. **Optimización del modelo:** Si el modelo no alcanza el rendimiento deseado, se realizan ajustes en la selección de características, hiperparámetros o algoritmos de optimización hasta que se logre un rendimiento aceptable.
7. **Uso del modelo para predicción:** Una vez que se ha optimizado el modelo, se puede utilizar para predecir el torque y la temperatura del estator en motores síncronos de imanes permanentes basados en las entradas de las variables mencionadas en la introducción.

3 Resultados y Discusión

3.1 Descripción de los datos

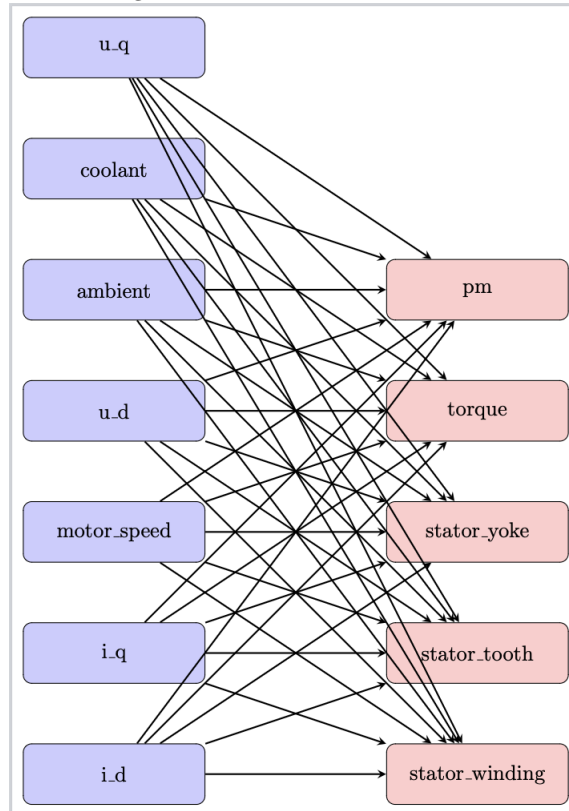
Los registros corresponden a mediciones realizadas a un motor síncrono de imán permanente (PMSM), los cuales fueron muestreados a una frecuencia de 2 Hz. El conjunto de datos contiene múltiples sesiones de medición, las cuales se pueden distinguir por el identificador de perfil (`profile_id`) y tienen una duración variable de entre una y seis horas. En total, se registraron 185 horas de operación del motor.

Cabe destacar que el motor es excitado por ciclos de conducción diseñados a mano, que establecen una velocidad de referencia y un par de referencia. Las corrientes y voltajes en coordenadas d/q son resultado de una estrategia de control estándar que intenta seguir la velocidad y el par de referencia, y las variables de velocidad y torque son las cantidades resultantes logradas por esa estrategia, derivadas de las corrientes y voltajes establecidos. La mayoría de los ciclos de conducción corresponden a caminatas aleatorias en el plano velocidad-par, con el fin de imitar ciclos de conducción del mundo real de manera más precisa que las excitaciones y rampas de subida y bajada constantes.

Table 1: Variables del conjunto de datos

Variable	Descripción
u.q	Tensión en el eje q del motor
coolant	Temperatura del refrigerante del motor
stator_winding	Temperatura del devanado del estator del motor
u.d	Tensión en el eje d del motor
stator_tooth	Temperatura del diente del estator del motor
motor_speed	Velocidad del motor
i.d	Corriente en el eje d del motor
i.q	Corriente en el eje q del motor
pm	Temperatura del imán permanente del motor
stator_yoke	Temperatura del yugo del estator del motor
ambient	Temperatura ambiente durante la medición
torque	Par del motor
profile_id	Identificador de la sesión de medición

Figure 1: Estructura del modelo



3.2 Preprocesamiento de datos

En esta subsección, se describe el preprocesamiento de los datos que se realizaron antes de entrenar el modelo de predicción.

TBD

3.3 Desempeño del modelo de predicción

En esta subsección, se presenta el desempeño del modelo de predicción entrenado en los datos descritos anteriormente.

TBD

References

3.4 Artículo científico

Jun Li, Thangarajah Akilan, (2022). Global Attention-based Encoder-Decoder LSTM Model for Temperature Prediction of Permanent Magnet Synchronous Motors. IEEE, 11.

3.5 Libro

Hastie, T., Tibshirani, R., Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer.

3.6 Web

Kirgiz, W. (2021). Electric Motor Temperature. Recuperado el 10 de enero de 2023, de <https://www.kaggle.com/datasets/wkirgsn/electric-motor-temperature>